

Classification Presse

Guide utilisateur

Projet L3 Informatique

Table des matières

1	Présentation du logiciel	2
2	Fonctionnalités principales	2
2.1	Construire le corpus	2
2.2	Lancer l'analyse	2
2.3	Classifier un article	3
3	Prérequis	3
4	Installation du paquet Debian	3
5	Premier lancement	3
6	Utilisation de l'interface	4
6.1	Étape 1 : construire le corpus	4
6.2	Étape 2 : lancer l'analyse	4
6.3	Étape 3 : classifier une URL	4
7	Comprendre les résultats	4
7.1	K-means	4
7.2	LDA	5
7.3	Régression logistique	5
8	Données et fichiers générés	5
9	Configuration des sources	5
10	Gestion de PostgreSQL	6
11	Messages d'erreur fréquents	6
11.1	Impossible d'extraire assez de texte	6
11.2	Résultat INCERTAIN	6
11.3	PostgreSQL inaccessible	6
12	Désinstallation	7
13	Code source	7
14	Limites connues	7
15	Résumé d'utilisation	7

1 Présentation du logiciel

Classification Presse est une application locale permettant de constituer un corpus d'articles de presse francophones, d'analyser leur contenu et de proposer un thème pour un nouvel article fourni sous forme d'URL.

Le logiciel travaille avec six thèmes :

- Tech ;
- Sciences ;
- Sport ;
- Politique ;
- Économie ;
- Culture.

L'application est conçue pour être utilisée principalement depuis une interface web locale ouverte dans le navigateur. Elle s'appuie sur Python, PostgreSQL et plusieurs bibliothèques de traitement automatique du langage et de fouille de données.

2 Fonctionnalités principales

L'interface présente trois actions principales.

2.1 Construire le corpus

Cette fonction efface le corpus précédent puis construit un nouveau corpus équilibré de **60 articles**, soit **10 articles pour chacun des 6 thèmes**.

Les sources utilisées sont définies dans le fichier :

```
config/sources.yaml
```

Le logiciel récupère les pages de presse, extrait le texte utile et enregistre les articles dans PostgreSQL.

2.2 Lancer l'analyse

Cette fonction lance la chaîne d'analyse du corpus :

1. nettoyage et préparation du texte ;
2. lemmatisation ;
3. construction des représentations numériques ;
4. clustering K-means ;
5. modélisation thématique LDA ;
6. évaluation ;
7. entraînement d'un classifieur supervisé par régression logistique ;
8. génération des graphiques de résultats et de comparaison.

À la fin de l'analyse, l'interface affiche notamment :

- le nombre d'articles ;
- le nombre de thèmes ;
- le nombre de sites ;
- la pureté et l'ARI pour K-means ;
- la pureté, l'ARI et la cohérence pour LDA ;
- l'accuracy et le F1-macro de la régression logistique ;
- les graphiques permettant d'interpréter et de comparer les résultats.

2.3 Classifier un article

L'utilisateur peut coller l'URL publique d'un article de presse.

Le logiciel :

1. télécharge la page ;
2. extrait le texte ;
3. applique le même prétraitement que pour le corpus ;
4. applique K-means, LDA et la régression logistique au nouvel article ;
5. affiche la proposition de thème obtenue avec chacune des trois méthodes ;
6. affiche des graphiques permettant de confronter les résultats ;
7. indique également si la décision de la régression logistique est acceptée ou marquée **INCERTAIN**.

Les trois scores affichés n'ont pas exactement la même signification : K-means fournit une mesure de proximité avec un cluster, LDA un poids de topic et la régression logistique une probabilité de classe.

La décision **INCERTAIN** concerne la régression logistique lorsque le modèle n'est pas suffisamment confiant pour proposer une décision ferme.

3 Prérequis

Le logiciel est destiné à un environnement Linux compatible avec les paquets Debian, par exemple Debian, Ubuntu ou Linux Mint.

Les principaux prérequis sont :

- Python 3 ;
- PostgreSQL ;
- `python3-venv` ;
- un navigateur web ;
- une connexion Internet pour la collecte des articles et l'installation initiale de certaines dépendances Python.

4 Installation du paquet Debian

Le logiciel est distribué sous la forme d'un paquet :

```
classification-presse_1.0.0-1_all.deb
```

Depuis le dossier contenant le fichier, exécuter :

```
sudo apt install ./classification-presse_1.0.0-1_all.deb
```

Une fois l'installation terminée, la commande principale est :

```
classification-presse
```

5 Premier lancement

Lors du premier lancement, le logiciel prépare son espace utilisateur et installe les dépendances Python nécessaires dans un environnement virtuel local.

Le dossier utilisateur est situé dans :

```
~/.local/share/classification-presse
```

Le code installé par le paquet Debian se trouve principalement dans :

`/usr/share/classification-presse`

Après la préparation, l'interface locale est ouverte dans le navigateur.

6 Utilisation de l'interface

6.1 Étape 1 : construire le corpus

Cliquer sur le bouton **Construire le corpus**.

Le logiciel supprime les anciens articles puis collecte un nouveau corpus.

Le résultat attendu est :

Thème	Nombre d'articles
Tech	10
Sciences	10
Sport	10
Politique	10
Économie	10
Culture	10
Total	60

Ce choix permet d'obtenir un corpus équilibré dans lequel aucun thème n'est surreprésenté.

6.2 Étape 2 : lancer l'analyse

Cliquer sur **Lancer l'analyse**.

L'analyse peut prendre un certain temps car plusieurs traitements sont effectués. Il faut attendre le message indiquant que l'analyse est terminée.

L'interface affiche ensuite les résultats des modèles.

6.3 Étape 3 : classifier une URL

Dans la zone prévue à cet effet :

1. copier l'URL complète d'un article public ;
2. la coller dans le champ de saisie ;
3. lancer la classification.

L'interface affiche les résultats des trois méthodes pour le même article. Il est donc possible de voir si K-means, LDA et la régression logistique proposent le même thème ou s'ils donnent des résultats différents.

Pour la régression logistique, l'interface affiche aussi la meilleure probabilité, l'écart avec la deuxième classe et la décision **ACCEPTÉE** ou **INCERTAIN**.

7 Comprendre les résultats

7.1 K-means

K-means est une méthode non supervisée. Elle regroupe les articles selon leur proximité dans l'espace TF-IDF sans utiliser directement leurs thèmes de référence pour construire les groupes.

Les mesures principales sont :

Pureté : proportion d'articles appartenant au thème majoritaire dans chaque groupe.

ARI : mesure de similarité entre les groupes trouvés automatiquement et les thèmes de référence.

7.2 LDA

LDA cherche des thèmes latents à partir des mots qui apparaissent ensemble dans les documents.

La cohérence LDA donne une indication sur la qualité sémantique des groupes de mots associés aux thèmes découverts.

7.3 Régression logistique

La régression logistique est utilisée comme modèle supervisé.

Elle apprend à partir des articles dont le thème est déjà connu, puis elle peut proposer un thème pour un nouvel article.

L'accuracy et le F1-macro sont calculés par validation croisée.

8 Données et fichiers générés

Le dossier `outputs/` contient les résultats produits pendant l'analyse.

Selon l'exécution, il peut notamment contenir :

- un export du corpus ;
- les résultats de K-means ;
- les résultats LDA ;
- les évaluations ;
- les fichiers du modèle supervisé ;
- la représentation TF-IDF ;
- les graphiques générés pour l'analyse et la comparaison des méthodes.

Ces fichiers sont produits automatiquement et ne doivent pas être modifiés manuellement pendant l'utilisation normale du logiciel.

9 Configuration des sources

Les sources sont définies dans :

`config/sources.yaml`

Chaque entrée indique principalement :

- une URL de départ ;
- un thème ;
- une limite d'articles.

Dans la configuration fournie, le logiciel utilise notamment Numerama et RFI pour constituer les six catégories du corpus.

10 Gestion de PostgreSQL

Le logiciel utilise PostgreSQL pour stocker le corpus de manière structurée.

La base permet de conserver notamment :

- l'URL ;
- le titre ;
- le texte ;
- le thème de référence ;
- le site ;
- certaines métadonnées ;
- un checksum servant notamment à détecter les doublons.

En cas de problème de configuration PostgreSQL, la commande suivante est disponible :

```
sudo classification-presse-db-setup
```

11 Messages d'erreur fréquents

11.1 Impossible d'extraire assez de texte

Exemple :

```
Impossible d'extraire assez de texte (0 mots, minimum 80).
```

Cela signifie généralement que :

- la structure du site n'est pas compatible avec l'extracteur ;
- la page ne contient pas suffisamment de texte ;
- le site bloque ou limite l'accès automatisé ;
- le contenu est chargé dynamiquement.

Ce message ne signifie pas que le classifieur est défectueux : l'échec se produit avant la classification, au moment de l'extraction.

11.2 Résultat INCERTAIN

Ce résultat est normal lorsque les probabilités du modèle sont trop faibles ou trop proches. Le logiciel préfère alors ne pas forcer une catégorie.

11.3 PostgreSQL inaccessible

Vérifier que PostgreSQL est démarré et que la configuration de connexion est correcte.

Si nécessaire :

```
sudo classification-presse-db-setup
```

12 Désinstallation

Pour supprimer le paquet installé :

```
sudo apt remove classification-presse
```

Les données utilisateur situées dans :

```
~/.local/share/classification-presse
```

peuvent éventuellement rester présentes après la désinstallation afin d'éviter de supprimer automatiquement les données personnelles de l'utilisateur.

13 Code source

Le logiciel est également fourni sous forme d'une archive de sources, par exemple :

```
classification-presse_1.0.0-1_source.tar.gz
```

Cette archive permet de consulter le code source et de reconstruire le logiciel.

14 Limites connues

Le logiciel est un projet universitaire et possède plusieurs limites :

- le corpus contient seulement 60 articles ;
- seuls deux médias principaux sont utilisés pour le corpus ;
- les catégories éditoriales des médias servent de labels de référence ;
- certains articles peuvent naturellement appartenir à plusieurs thèmes ;
- certains sites web ne peuvent pas être correctement extraits ;
- les performances mesurées sur le corpus ne garantissent pas les mêmes performances sur l'ensemble de la presse française.

15 Résumé d'utilisation

1. installer le paquet `.deb` ;
2. lancer `classification-presse` ;
3. construire le corpus ;
4. lancer l'analyse ;
5. consulter les résultats ;
6. tester éventuellement une URL extérieure.